

UNIVERSITE IBN ZOHR

FACULTE DES SCIENCES

Département Informatique

Master de recherche de science des données

Projet Hadoop et Spark

Présenté par :

- > Ousayd Lahcen
- > Bentaher Noura
- > Elkhalfaoui Yasmina
- Saidi Souad

Encadré par : Mr. Kabbadj

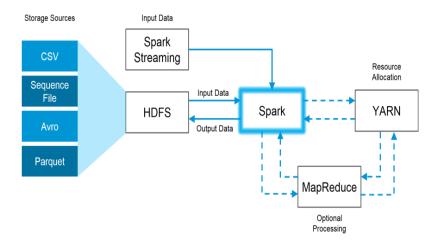
I- Introduction:

Apache Hadoop et Apache Spark sont tous les deux des Frameworks open-source pour le traitement des données volumineuses avec quelques différences clés.

Hadoop utilise MapReduce pour traiter les données, tandis que Spark utilise des ensembles de données distribués résilients (RDD). Hadoop dispose d'un système de fichiers distribués (HDFS), ce qui signifie que les fichiers de données peuvent être stockés sur plusieurs machines.

Le système de fichiers est évolutif, car des serveurs et des machines peuvent être ajoutés pour accueillir des volumes croissants de données. Spark ne fournit pas de système de stockage de fichiers distribué, il est donc principalement utilisé pour le calcul.

La bonne nouvelle est que Spark est entièrement compatible avec Hadoop et fonctionne sans problème avec Hadoop Distributed File System (HDFS). Ainsi, lorsque la taille des données est trop grande pour que Spark puisse les gérer en mémoire, Hadoop peut aider à surmonter cet obstacle grâce à sa fonctionnalité HDFS. Voici un exemple visuel de la façon dont Spark et Hadoop peuvent travailler ensemble :



L'image ci-dessus montre comment Spark utilise les meilleures parties de Hadoop à travers HDFS pour la lecture et le stockage des données, MapReduce pour le traitement optionnel et YARN pour l'allocation des ressources.

II- Installation du Hadoop:

Étape 1 : Installation de Java :

Java est le prérequis principal pour Hadoop. Tout d'abord, vous devez vérifier l'existence de java dans votre système en utilisant « java -version ».

```
hadoopusr@slave3:~

Fichier Édition Affichage Rechercher Terminal Aide

hadoopusr@slave3:~$ java -version
openjdk version "11.0.13" 2021-10-19
OpenJDK Runtime Environment (build 11.0.13+8-Ubuntu-Oubuntu1.20.04)
OpenJDK 64-Bit Server VM (build 11.0.13+8-Ubuntu-Oubuntu1.20.04, mixed mode, sharing)
hadoopusr@slave3:~$
```

Étape 2 : Après la vérification de l'installation de java, nous avons besoin d'un utilisateur dédié pour l'installation de Hadoop avec le nom hadoopusr, on utilisant les commandes suivante :

- sudo addgroup hadoop
- sudo adduser --ingroup hadoop hadoopusr

Étape 3 : maintenant on ajoute l'utilisateur « hadoopusr » au groupe « sudo »

sudo adduser hadoopusr sudo

Étape 4 : Une fois que vous avez téléchargé hadoop-2.9.0.tar.gz , maintenant nous extrayons ce fichier avec la commande ci-dessous :

• sudo tar - xvzf hadoop-2.9.0.tar.gz

Étape 6: Maintenant, nous devons déplacer ce dossier extrait vers l'utilisateur hadoopusr et puis nous devons changer la propriété de ce dossier :

- sudo mv hadoop /usr/local/hadoop
- sudo chown -R hadoopusr /us/local

Étape 7 : configurer notre fichier . /bashrc .

- sudo nano ~/.bashrc
- Ajouter les lignes suivant :

```
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
export HADOOP_HOME=/usr/local/hadoop
export PATH=$PATH:$HADOOP_HOME/bin
export PATH=$PATH:$HADOOP_HOME/sbin
export HADOOP_MAPRED_HOME=$HADOOP_HOME
export HADOOP_COMMON_HOME=$HADOOP_HOME
export HADOOP_HOME=$HADOOP_HOME
export HADOOP_HOME=$HADOOP_HOME
export YARN_HOME=$HADOOP_HOME
export HADOOP_COMMON_LIB_NATIVE_DIR=$HADOOP_HOME/lib/native
export HADOOP_OPTS="-Djava.library.path=$HADOOP_HOME/lib"
```

source ~/.bashrc

Étape 8:

- sudo nano /usr/local/hadoop/etc/hadoop/hadoop-env.sh
- Ajouter JAVA_HOME

```
# The java implementation to use.
#export JAVA_HOME=$\{JAVA_HOME}\
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
```

Étape 9 : Pour les autres fichiers de configuration de Hadoop , on va le configure dans la deuxième partie

III- Configuration multi-nœuds (master et slaves):

1. Mettre à jour le nom d'hôte on master et slaves.

Machine master nommée master, les machines slaves nommée respectivement slave1, slave2 et slave3 dans notre situation.

2. Mettre à jour fichier /etc/hosts on master et slaves :

Ajouter les adresses IPs de machine master et slaves :

```
hadoopusr@slave3: ~
 Fichier Édition Affichage Rechercher Terminal Aide
  GNU nano 4.8
                                       /etc/hosts
127.0.0.1
                localhost
\overline{1}27.0.1.1
                Yasmina-Linux
192.168.43.32 master
192.168.43.80 slave2
192.168.43.237 slave1
192.168.43.163 slave3
        ip6-localhost ip6-loopback
fe00::0 ip6-localnet
ff00::0 ip6-mcastprefix
ff02::1 ip6-allnodes
ff02::2 ip6-allrouters
```

3. Configuration de SSH:

Install SSH dans toutes les machines, pour être capable de communiquer entre eux sans mot de passe :

sudo apt-get install openssh-server

```
@slave1:-$ ssh master
thenticity of host 'master (192.168.220.185)' can't be established.
key fingerprint is SHA256:4dh6QSlhNQIBM9m2TTQTSFLRMdBPe8NDdM2pDn0CkYU.
u sure you want to continue connecting (yes/no)? yes
g: Permanently added 'master,192.168.220.185' (ECDSA) to the list of know
e to Ubuntu 16.04.1 LTS (GNU/Linux 4.4.0-45-generic x86_64)
umentation: https://help.ubuntu.com
agement: https://landscape.canonical.com
port: https://ubuntu.com/advantage
kages can be updated.
tes are security updates.
ogin: Mon Oct 31 01:25:24 2016 from 192.168.220.185
@master:-$
```

4. Changer fichier core-site.xml:

```
http://www.apache.org/licenses/LICENSE-2.0

Unless required by applicable law or agreed to in writing, software distributed under the License is distributed on an "AS IS" BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied. See the License for the specific language governing permissions and limitations under the License. See accompanying LICENSE file.

-->

<!-- Put site-specific property overrides in this file. -->

<configuration>

</configuration>

</configuration>

</configuration>

</configuration>
```

5. Changer fichier hdfs-site.xml:

> Dans Master machine :

```
hadoopusr@master:/usr/local/hadoop/etc/hadoop

File Edit View Search Terminal Help

GNU nano 4.8 hdfs-site.xml

distributed under the License is distributed on an "AS IS" BASIS,
WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.
See the License for the specific language governing permissions and
limitations under the License. See accompanying LICENSE file.

-->

<!-- Put site-specific property overrides in this file. -->

configuration>
```

> Dans Slaves machines :

```
GNU nano 4.8
WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.
See the License for the specific language governing permissions and limitations under the License. See accompanying LICENSE file.
-->
<!-- Put site-specific property overrides in this file. -->
<configuration>
sproperty>
name>dfs.replication</name>
<value>3</value>
</property>
chame>dfs.datanode.data.dir</name>
<value>file:/usr/local/hadoop_tmp/hdfs/datanode</value>

sylue>file:/usr/local/hadoop_tmp/hdfs/datanode
```

6. Changer fichier yarn-site.xml:

> Dans Master et Slaves :

7. Changer les fichiers masters et slaves dans Master hôte seulement :

> Fichier masters:

> Fichiers slaves :

```
hadoopusr@master: /usr/local/hadoop/etc/hadoop

File Edit View Search Terminal Help

GNU nano 4.8 slaves
slave1
slave2
slave3
```

8. Créer le dossier namenode uniquement dans master :

- sudo rm -rf /usr/local/hadoop_tmp
- sudo mkdir -p /usr/local/hadoop_tmp/hdfs/namenode
- sudo chown hadoopusr : hadoop -R /usr/local/hadoop_tmp/
- sudo chmod 777 /usr/local/hadoop_tmp/hdfs/namenode

9. Créer le dossier datanode uniquement dans slaves :

- sudo rm -rf /usr/local/hadoop_tmp
- sudo mkdir -p /usr/local/hadoop_tmp/hdfs/datanode
- sudo chown hadoopusr : hadoop -R /usr/local/hadoop_tmp/
- sudo chmod 777 /usr/local/hadoop_tmp/hdfs/datanode

10.Formater le Namenode (Master uniquement) :

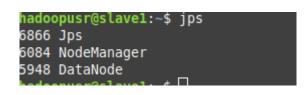
• hdfs namenode -format

11. Start the dfs & Yarn (Master uniquement):

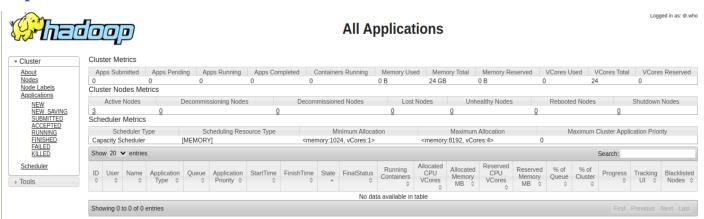
• start-all.sh

12. Jps dans master et slaves :

```
hadoopusr@master:/usr/local/hadoop/etc/hadoop$ jps
4482 Jps
4217 ResourceManager
3853 NameNode
4062 SecondaryNameNode
```

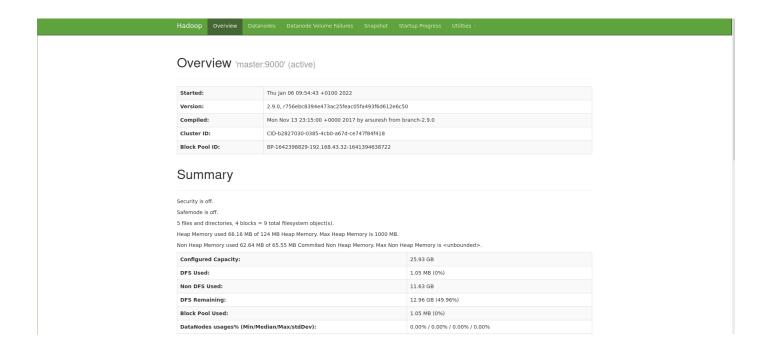


http://master:8088



http//master:50070

> Afficher Namenode :



> Afficher datanode disponible :

						_		
Node	↓ <u>L</u> Http Address	Last contact	Last Block Report	† Capacity	↓↑ Blocks	Block pool used	↓† Version	
✓slave1:50010 (192.168.43.237:50010)	http://slave1:50075	0s	13m	95.62 GB	0	32 KB (0%)	2.9.0	
✓slave2:50010 (192.168.43.80:50010)	http://slave2:50075	0s	13m	25.93 GB	2	84.14 KB (0%)	2.9.0	
✓slave3:50010 (192.168.43.163:50010)	http://slave3:50075	2s	13m	36.53 GB	2	94.12 KB (0%)	2.9.0	

IV- Configuration du Spark:

1. Installation du Spark:

• Extraire le package: tar -xvf spark-3.0.3-bin-hadoop2.7.tgz

mv spark-3.0.3-bin-hadoop2.7 /usr/local/spark

• Ajouter les ligne suivante au fichier ~/. bashrc :

```
export SPARK_HOME=/usr/local/spark
export PATH=$PATH:$SPARK_HOME/bin
```

• Les deux lignes suivantes utilisant pour intégrer Spark avec Yarn Hadoop :

```
export HADOOP_CONF_DIR=/usr/local/hadoop/etc/hadoop
export LD_LIBRARY_PATH=/usr/local/hadoop/lib/native:$LD_LIBRARY_PATH
```

• Mettre à jour les fichiers suivants :

1- spark-env.sh:

```
HADOOP_CONF_DIR="/usr/local/hadoop/etc/hadoop"
SPARK_YARN_QUEUE="<mark>default"___</mark>
SPARK_MASTER_HOST=master
SPARK_DRIVER_MEMORY=10G
```

2- slaves:

```
# A Spark Worker will be started on each of the machines listed below.
master
slave1
slave2
slave3
```

2. Installation du jupyter et configure Pyspark :

Pour installation de jupyter on utilise command suivant :

• pip Install jupyter

PySpark est une interface pour Apache Spark en Python. Alors on va configurer le fichier ~/.bachrc pour pouvoir utiliser jupyter dans Spark .

```
export PYSPARK_PYTHON=python3
export PYSPARK_DRIVER_PYTHON=jupyter
export PYSPARK_DRIVER_PYTHON_OPTS='notebook'
```

3. Start Spark (master uniquement):

```
hadoopusr@master:~$ cd /usr/local/spark/sbin
hadoopusr@master:/usr/local/spark/sbin$ ./start-all.sh
starting org.apache.spark.deploy.master.Master, logging to /usr/local/spark/logs/spark-hadoop
usr-org.apache.spark.deploy.master.Master-1-master.out
slave3: starting org.apache.spark.deploy.worker.Worker, logging to /usr/local/spark/logs/spar
k-hadoopusr-org.apache.spark.deploy.worker.Worker-1-slave3.out
master: starting org.apache.spark.deploy.worker.Worker, logging to /usr/local/spark/logs/spar
k-hadoopusr-org.apache.spark.deploy.worker.Worker-1-master.out
slave2: /usr/local/spark/conf/spark-env.sh: line 73: SPARK_MASTER_HOST: command not found
slave2: starting org.apache.spark.deploy.worker.Worker, logging to /usr/local/spark/logs/spar
k-hadoopusr-org.apache.spark.deploy.worker.Worker-1-slave2.out
slave1: starting org.apache.spark.deploy.worker.Worker, logging to /usr/local/spark/logs/spar
k-hadoopusr-org.apache.spark.deploy.worker.Worker.loslave1.out
hadoopusr@master:/usr/local/spark/sbin$
```

4. Jps après start Spark:

```
hadoopusr@slave3:~$ jps
3478 Jps
2568 NodeManager
2876 Worker
2431 DataNode
```

5. http://master :8080 :

Spark Master at spark://master:7077



Dunning Applications (A)

6. Start Pyspark shell application:

```
hadoopusr@master:/usr/local/spark/sbin$ pyspark --master spark://master:7077
             094 NotebookApp] Serving notebooks from local directory: /usr/local/
spark/sbin
           1.094 NotebookApp] Jupyter Notebook 6.4.6 is running at:
1.094 NotebookApp] http://localhost:8888/?token=b92c5feee599bbf1750a50
95c9676fc419c26c8abb8729e8
                                or http://127.0.0.1:8888/?token=b92c5feee599bbf175
0a5095c9676fc419c26c8abb8729e8
                               Use Control-C to stop this server and shut down all
 kernels (twice to skip confirmation).
    To access the notebook, open this file in a browser:
        file:///home/hadoopusr/.local/share/jupyter/runtime/nbserver-7921-open.h
tml
    Or copy and paste one of these URLs:
        http://localhost:8888/?token=b92c5feee599bbf1750a5095c9676fc419c26c8abb8
729e8
     or http://127.0.0.1:8888/?token=b92c5feee599bbf1750a5095c9676fc419c26c8abb8
729e8
```

→ Running Applications (1)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
app-20220106143923-0000 (kill)	PySparkShell	8	1024.0 MiB		2022/01/06 14:39:23	hadoopusr	RUNNING	30 s

V- Implémentation:

1- Copie les Datasets de local à HDFS :

Les datasets adoptant dans cette implémentation sont Titanic et Banque dataset. Alors on va copier ces deux fichier csv dans notre HDFS, en utilisant la commande suivante : hdfs dfs -put

```
hadoopusr@master:/usr/local/spark$ hdfs dfs -put /usr/local/titanic.csv /titanic.csv
WARNING: An illegal reflective access operation has occurred
WARNING: Illegal reflective access by org.apache.hadoop.security.authentication.util.KerberosU
til (file:/usr/local/hadoop/share/hadoop/common/lib/hadoop-auth-2.9.0.jar) to method sun.secur
ity.krb5.Config.getInstance()
WARNING: Please consider reporting this to the maintainers of org.apache.hadoop.security.authe
ntication.util.KerberosUtil
WARNING: Use --illegal-access=warn to enable warnings of further illegal reflective access ope
```

```
hadoopusr@master:~$ hdfs dfs -put /usr/local/bank.csv /bank.csv
WARNING: An illegal reflective access operation has occurred
WARNING: Illegal reflective access by org.apache.hadoop.security.authentication.
util.KerberosUtil (file:/usr/local/hadoop/share/hadoop/common/lib/hadoop-auth-2.
9.0.jar) to method sun.security.krb5.Config.getInstance()
WARNING: Please consider reporting this to the maintainers of org.apache.hadoop.
security.authentication.util.KerberosUtil
WARNING: Use --illegal-access=warn to enable warnings of further illegal reflect
```

2- Load data from HDFS to Spark jupyter:

Spark Session est le point d'entrée pour programmer Spark avec le jeu de données. Ici nous permet de lire et sauvegarder les données à partir de HDFS

```
In [1]: M import numpy as np # linear algebra
             import pandas as pd
In [1]: M from pyspark.sql import SparkSession
             spark = SparkSession.builder.appName('titanic').getOrCreate()
In [2]: M df = spark.read.csv('hdfs:///train.csv', header = True, inferSchema=True)
             df test = spark.read.csv('hdfs:///test.csv', header = True, inferSchema=True)
In [3]: ▶ df.printSchema()
               |-- PassengerId: integer (nullable = true)
               |-- Survived: integer (nullable = true)
               -- Pclass: integer (nullable = true)
               |-- Name: string (nullable = true)
|-- Sex: string (nullable = true)
|-- Age: double (nullable = true)
               -- SibSp: integer (nullable = true)
-- Parch: integer (nullable = true)
                -- Ticket: string (nullable = true)
                -- Fare: double (nullable = true)
                -- Cabin: string (nullable = true)
                -- Embarked: string (nullable = true)
```

```
In [5]: M df.show()
         |PassengerId|Survived|Pclass|
                                               Namel Sex! Age|SibSp|Parch|
                                                                               Ticket| Fare|Cabin|Embark
         ed
                 +---
                   1|
                                3|Braund, Mr. Owen ...| male|22.0|
                                                                1|
                                                                     0|
                                                                             A/5 21171| 7.25| null|
         SI
                   21
                                1|Cumings, Mrs. Joh...|female|38.0|
                                                                              PC 17599[71.2833] C85[
                          11
         CI
                   3|
                          1
                                3|Heikkinen, Miss. ...|female|26.0|
                                                                     0|STON/02. 3101282| 7.925| null|
         SI
                   41
                          11
                                1|Futrelle, Mrs. Ja...|female|35.0|
                                                                1|
                                                                     01
                                                                               113803| 53.1| C123|
         SI
                   51
                          01
                                3|Allen, Mr. Willia...| male|35.0|
                                                                0|
                                                                     0
                                                                               373450| 8.05| null|
         SI
                                                                               330877| 8.4583| null|
                   61
                                   Moran, Mr. James| male|null|
                                                                     01
                          01
                                                                01
         QI
                   71
                                1|McCarthy, Mr. Tim...| male|54.0|
                                                                     01
                                                                                17463 | 51.8625 | E46 |
                          01
                                                                01
         SI
                                                                               349909| 21.075| null|
                   81
                          01
                                3|Palsson, Master. ... | male | 2.0|
                                                                3|
                                                                     11
         SI
                   9|
                          1|
                                3|Johnson, Mrs. Osc...|female|27.0|
                                                                01
                                                                     21
                                                                               347742|11.1333| null|
          SI
                                                                               237736|30.0708| null|
                  101
                          11
                                2|Nasser, Mrs. Nich...|female|14.0|
                                                                11
                                                                     01
         CI
                  111
                          11
                                3|Sandstrom, Miss. ...|female| 4.0|
                                                                11
                                                                     11
                                                                              PP 9549  16.7  G6
         SI
                                1|Bonnell, Miss. El...|female|58.0|
                                                                               113783| 26.55| C103|
                  121
                                                                01
                                                                     01
                          11
```

3-Appliquer Random Forest sur Titanic dataset :

Random Forest

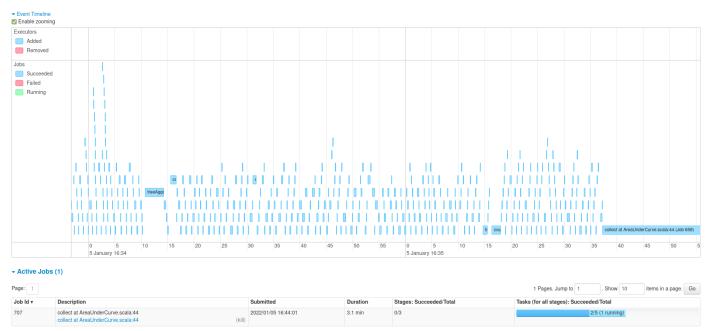
```
|prediction|Survived|
                                           features
                        0|[1.0,24.0,0.0,0.0...|
0|[1.0,24.0,0.0,1.0...|
          1.01
          1.01
                        0|[1.0,31.0,0.0,0.0...
0|[1.0,31.0,1.0,0.0...
          1.0
          1.0
                         0 [1.0,33.0,0.0,0.0...
          0.0
          1.0
                         0 | [1.0,36.0,1.0,0.0...
          1.0
                         0|[1.0,37.0,0.0,1.0.
                        0|(5,[0,1],[1.0,40.0])
0|[1.0,46.0,0.0,0.0...
0|[1.0,47.0,0.0,0.0...
          0.0
          1.0
          1.0
          0.01
          1.0
                         0 [1.0,52.0,1.0,1.0...
                         0 [1.0,54.0,0.0,1.0...
          1.0
                         0 [1.0,64.0,1.0,4.0...
          1.01
          0.0
                         0 | [1.0,71.0,0.0,0.0...
          1.0
                         1 [1.0,16.0,0.0,1.0...
          1.0
                         1 [1.0,18.0,0.0,2.0...
          1.01
                         1 | [1.0,19.0,0.0,2.0...
                        1|[1.0,21.0,2.0,2.0...|
1|[1.0,24.0,0.0,0.0...|
          1.01
          1.0
only showing top 20 rows
```

Accuracy of Random forest is = 0.666667 Test Error of Random forest = 0.333333

4-Applique Logistique Régression sur Titanic dataset :

```
In [9]: ▶ from pyspark.ml import Pipeline
           log reg = LogisticRegression(featuresCol = 'features', labelCol = 'Survived')
assembler, log_reg])
In [11]: M train, test = final data.randomSplit([0.7, 0.3])
In [12]: M fit model = pipeline.fit(train)
In [13]: M results = fit_model.transform(test)
In [14]: M results.select('prediction', 'Survived').show(3)
           |prediction|Survived|
                  1.0|
                            01
                  1.0
                            0
                  1.01
                            01
           only showing top 3 rows
In [16]: M from pyspark.ml.evaluation import BinaryClassificationEvaluator
           evalu = BinaryClassificationEvaluator(rawPredictionCol = 'rawPrediction', labelCol = 'Survived')
           AUC = evalu.evaluate(results)
           AUC
   Out[16]: 0.8512512512512513
```

Dans http://master:4040 on peut observer les jobs exécutent sur pyspark application :



VI- Conclusion:

La Réalisation de ce travail nous a poussés de pratiquer et d'appliquer sur terrain toutes nos acquisitions et nos connaissances théoriques et d'une autre part, on a bien touché la notion de synchronisation entre les nœuds d'un cluster afin d'être capable d'y stocker des données et d'y exécuter des programmes.

Au cours de notre travail, on rencontre pas mal des problèmes et des difficultés dans la plupart de temps, ils sont liés à la configuration soit de Hadoop ou Spark, le grand (principal) problème qu'on rencontrée est liée l'installation de pig et spark.